

Deteksi Penyakit Daun Padi Menggunakan Ensemble Learning Boosting dengan DenseNet-121 dan ResNet-101

Rice Leaf Disease Detection Using Ensemble Learning Boosting with DenseNet-121 and ResNet-101

Muhammad Shafwan Abdullah, Alam Rahmatulloh*

Program Studi Informatika, Universitas Siliwangi, Tasikmalaya, Indonesia

*E-mail: alam@unsil.ac.id

Abstrak

Pendeteksi penyakit pada daun padi penting untuk diketahui oleh petani agar dapat menindaklanjuti secara cepat dan penyakit tersebut tidak tersebar ke tanaman padi lainnya, petani harus mengetahui penyakit yang dialami tanamannya beserta langkah yang harus dilakukan selanjutnya, tujuan dari dilakukannya penelitian ini yaitu dibuatkannya sebuah aplikasi yang dapat mendeteksi penyakit pada daun padi sehingga petani dapat mengetahui penyakit dan bagaimana cara untuk mencegah dan menyembuhkannya secara cepat. Metode yang digunakan dalam penelitian ini adalah dengan mengimplementasikan deep learning pada aplikasi yang dibuat dengan metode ensemble learning boosting yaitu penggabungan dari premodel antara DenseNet-121 dan ResNet-101 dan adanya augmentasi data untuk memperbanyak data uji. Hasil dari penelitian ini yaitu telah dibuatnya sebuah aplikasi dengan model deep learning dengan dataset yang berisikan kelas brown spot, healthy, hispa, dan leaf blast dengan total 836 gambar yang mampu mendeteksi penyakit pada daun tumbuhan padi dengan akurasi pelatihan 79.86% pada model DenseNet-121 dan akurasi pelatihan 80.02% pada model ResNet-121 dengan nilai akurasi pada ensemble learning yaitu sebesar 52.69%.

Kata kunci: Penyakit Daun Padi, Deep Learning, Ensemble Learning, Densenet-121, ResNet-101

Abstract

Detecting diseases in rice leaves is important for farmers to know so that they can follow up quickly and the disease does not spread to other rice plants, farmers must know the diseases experienced by their plants and the steps that must be taken next. The aim of this research is to create an application that can detect diseases on rice leaves so that farmers can know the disease and how to prevent and cure it quickly. The method used in this research is to implement deep learning in applications created using the ensemble learning boosting method, namely combining premodels between DenseNet-121 and ResNet-101 and data augmentation to increase test data. The result of this research is that an application has been created with a deep learning model with a dataset containing brown spot, healthy, hispa and leaf blast classes with a total of 836 images that are able to detect disease on rice plant leaves with a training accuracy of 79.86% on the DenseNet-121 model. and training accuracy of 80.02% on the ResNet-121 model with an accuracy value on ensemble learning of 52.69%.

Keywords: Rice Leaf Disease, Deep Learning, Ensemble Learning, Densenet-121, ResNet-101

Naskah diterima xx Jan. 2024; direvisi xx Feb. 2024; dipublikasikan xx Apr. 2024.
JAMIKA is licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.



I. PENDAHULUAN

Beras merupakan kebutuhan pokok sehari-hari bagi sebagian besar masyarakat Indonesia karena rakyat Indonesia terbiasa menggunakan nasi untuk kebutuhan karbohidratnya. Untuk mendapatkan beras maka dibutuhkan proses pengolahan dari padi menjadi beras agar dapat dimasak lalu dimakan sehingga tanaman padi sangat penting bagi masyarakat Indonesia [1], untuk menjaga tanaman padi tetap sehat dan bagus maka dibutuhkan pemeliharaan untuk menjaga tanaman padi dari segala jenis hama yang dapat membuat tanaman padi terkontaminasi atau sakit, hama atau penyakit pada tanaman padi sering menyebabkan kerugian besar pada petani padi di Indonesia yang merupakan sebuah ancaman serius yang dapat mengancam produksi padi

[2], salah satu cara untuk mengatasi masalah hama pada tanaman padi yaitu dengan mengobati tanaman padi yang sudah terkontaminasi, hal ini bisa dilakukan dengan cara petani melakukan pemeriksaan yang teratur sehingga jika ditemukan tanaman padi yang sudah terkontaminasi, maka petani dapat melakukan pengobatan agar tanaman padi dapat sehat semua dan penyakit tersebut tidak menyebar ke tanaman padi lainnya.

Terdapat banyak jenis penyakit bagi tanaman padi dari kalangan bakteri, virus, dan jamur seperti *Blast*, *Brown spot*, *Bacterial Leaf Blight*, *Sheath Blight*, dan *Turgor* yang dapat merusak daun dari tanaman padi dan secara signifikan menurunkan kualitas dan kuantitas dari padi yang didapatkan [3], penting bagi petani untuk mengetahui penyakit dari tanaman padi secara mendalam dari jenis penyakitnya apa dan bagaimana cara untuk menyembuhkannya maupun pencegahannya.

Tujuan dilakukannya penelitian ini yaitu agar petani tanaman padi dapat mengetahui berbagai macam penyakit yang dapat dialami dari tanaman padi dan apa yang harus dilakukan saat tanaman padi terkena penyakit, dengan penggunaan aplikasi dari penelitian ini, maka saat ada tanaman padi yang terdapat kontaminasi atau penyakit, petani dapat segera menggunakan aplikasi ini dengan memotret dari tanaman padi yang terkontaminasi atau terkena penyakit dan akan muncul jenis penyakit yang dialami beserta langkah apa yang petani harus lakukan untuk menyembuhkan ataupun mencegahnya untuk tidak terjadi kembali.

Pada pembuatan aplikasi deteksi penyakit pada daun padi digunakan metode *Convolutional Neural Network* (CNN) dengan metode *ensemble learning* yang dimana digunakannya model *DenseNet-121* dan *ResNet-101* yang dimana model *DenseNet-121* biasa digunakan untuk kebutuhan mengekstraksi fitur-fitur mendalam pada masukan gambar terdalam [4] dan model *ResNet-101* biasa digunakan untuk meningkatkan tugas pengenalan pola gambar dengan memanfaatkan sisa pembelajaran untuk masalah gradien yang kosong [5], sehingga diharapkan model yang dibuat pada penelitian ini dapat mendeteksi gambar mulai dari gambar yang simpel maupun kompleks secara akurat,

Terdapat penelitian serupa yaitu mendeteksi penyakit pada daun padi berdasarkan jenisnya dengan menggunakan *Convolutional Neural Network* (CNN) dengan base model *Inception V3* menggunakan dataset dengan 240 data yang dibagi menjadi 3 kelas yang terdiri dari 80 data yang dimana mendapatkan akurasi sebesar 93,75% dan nilai kehilangan sebesar 0,3076, model yang didapatkan cukup baik dalam akurasinya namun jika dibandingkan dengan peneliti lainnya masih kurang dapat bersaing [6].

Terdapat penelitian serupa lagi yang dimana menggunakan metode *Convolutional Neural Network* dengan model dasar dari *ResNet-50* untuk mengklasifikasi penyakit pada tanaman padi yang terdiri dari *bacterial blight blast*, *brown spot*, dan *tungro*. Hasil dari penelitian ini yaitu berhasil dibuatnya sebuah model yang mampu mengidentifikasi dan mengkategorisasi secara akurat penyakit pada tanaman padi dengan hampir mencapai 100% pada skor F1, akurasi, presisi, dan *recall* [7]. Terdapat Peneliti lain yang serupa berupa deteksi penyakit pada padi yang dimana menggunakan *pre-trained Convolutional Neural Network* (CNN yang dimana dapat memperlihatkan performa yang dianjurkan seperti *ResNet-50* dan *ResNet-101* yang dimana mampu mendapat akurasi sebesar 91% dan 92% secara berurutan. [8].

Penelitian lain yang serupa yaitu dibuatnya deteksi penyakit pada daun padi menggunakan model *DenseNet-121* dan UNet dengan dataset yang memiliki 1120 gambar yang dimana dapat menghasilkan akurasi sebesar 95.23% [9]. Penelitian lain juga meneliti untuk deteksi penyakit pada daun padi dengan menggunakan model *DenseNet-121* yang kemudian dilakukan evaluasi dengan menggunakan beberapa pendekatan seperti penggunaan Adam, RMSprop, *Gradient Descent* optimasi yang memberi masing-masing 95.40%, 98.49%, dan 93.50% akurasi [10].


Terdapat penelitian serupa berupa aplikasi klasifikasi penyakit pada tanaman padi menggunakan pendekatan *Convolutional Neural Network* (CNN) dengan menggunakan *DenseNet-121* dan augmentasi data, dataset terdiri dari 750 citra dengan tiga jenis kelas yaitu *brown spot*, *blast*, dan *blight* dengan hasil akurasi sebesar 99,17% dan nilai kehilangan yaitu 0,0355 [11].

Pada Penelitian serupa yaitu dibuatnya aplikasi klasifikasi *Colorectal Cancer* (CLC) delapan kelas yang menggunakan kombinasi dari *DenseNet-121* dan *ResNet-101* untuk meningkatkan performa dari ekstraksi fitur untuk klasifikasi yang didapatkan akurasi dari skor F1 dengan perkiraan 0.93 [12].

Rangkuman dari penelitian yang dilakukan yaitu dilakukannya penggabungan model dari *DenseNet-121* dan *ResNet-101* dengan menggunakan metode *ensemble learning* dengan metode *boosting* untuk mendeteksi penyakit pada daun tanaman padi sehingga petani dapat mengetahui secara langsung langkah yang harus dilakukan ketika menemui tanamannya telah terkontaminasi atau memiliki penyakit yang diharapkan para petani padi dapat mengoptimalkan hasil panennya sehingga tidak terjadi kekurangan beras yang dimana merupakan bahan pangan pokok mayoritas masyarakat Indonesia.

II. METODE PENELITIAN

Metode penelitian yang dilakukan yaitu sesuai dengan diagram alur yang tertera pada gambar 1.



Gambar 1. Diagram alur metode penelitian

Pengumpulan Data


Tahap pertama dari metode penelitian yang dilakukan pada penelitian ini yaitu dilakukannya pengumpulan data, data sendiri memiliki arti yang berarti sebuah kumpulan informasi atau fakta mentah yang terdiri dari simbol, angka, kata-kata, atau gambar [13]. Data berperan penting untuk penelitian karena berfungsi sebagai fondasi untuk penelitian ilmiah, memungkinkan pengumpulan, pembuatan, kurasi, dan analisis yang diperlukan untuk kebutuhan ilmiah walaupun adanya ketidaklengkapan pada setiap kumpulan data, sehingga adanya istilah *Garbage In Garbage Out* (GIGO) yaitu jika data yang dimasukkannya jelek ataupun tidak merepresentasikan keadaan dunia nyata, maka hasil yang dikeluarkan pun akan jelek juga, karena itu data yang bagus dan dapat merepresentasikan keadaan dunia nyata sangat dibutuhkan [14].

Data yang digunakan dalam penelitian ini yaitu dataset penyakit pada tanaman padi dari Kaggle.com yaitu *Rice Leafs* dari Shayan Riyaz. *Dataset* ini memiliki dua bagian yaitu data pelatihan dan data validasi dengan masing-masing memiliki empat kelas yaitu *brownspot*, *healthy*, *hispa*, dan *leafblast* dengan total gambar yaitu 836 gambar dengan proporsi 669 gambar untuk data training dan 167 gambar untuk data validasi seperti yang ada pada tabel 1.

TABEL 1
JUMLAH DATASET RICELEAF

Kelas	Training Data	Validation Data
brownspot	104	26
healthy	297	74
hispa	113	28
leafblast	155	39
Total	669	167

Lalu untuk melihat contoh gambar *dataset* dari masing-masing kelas yang terdiri dari *brownspot*, *healthy*, *hispa*, dan *leafblast* berurutan sesuai baris dapat dilihat pada gambar 2.



Gambar 2. Contoh Gambar dari Dataset

Pemrosesan Awal Data

Tahap selanjutnya yaitu dilakukannya pemrosesan awal data, pemrosesan awal data atau *preprocessing data* adalah langkah yang penting untuk pemrosesan penambangan data, pemrosesan awal data biasanya terkait dengan pembersihan, pengubahan, dan integrasi pada data agar siap diolah untuk analisis [15]. Langkah pemrosesan awal data yang digunakan pada penelitian ini yaitu augmentasi data, augmentasi data dilakukan untuk memanipulasi data sehingga dari satu sumber data atau gambar dapat dimanipulasi seperti gambar tersebut dilakukan skala ulang, dimiringkan, diperdekat, diperkecil ataupun diperbesar, dan perubahan pencahayaan sehingga bisa memperbanyak jumlah dataset, hal ini berguna jika dataset yang dimiliki tidak memiliki jumlah yang besar sehingga dapat meningkatkan akurasi dari model.

Klasifikasi Data

Setelah dilakukan pemrosesan data, maka langkah selanjutnya yaitu klasifikasi data, langkah pertama yang dilakukan pada tahap ini yaitu dengan memuat model DenseNet-121 dan ResNet-101 dengan parameter *weights* berisi *imagenet*, *include top* berisi *false*, dan bentuk masukan $224 \times 224 \times 3$ yang dimuat dari *library 'keras.application'*.

DenseNet-121 dikenal dengan kelebihanannya dalam menyeimbangkan penskalaan dan keefisienannya dalam proses ekstraksi fitur, performa yang mengalahkan kedua metode tradisional dan model dari *Convolutional Neural Network (CNN)* [16]. ResNet-101 merupakan sebuah arsitektur jaringan sisa mendalam yang digunakan sebagai ekstraksi fitur yang dapat meningkatkan akurasi deteksi dan kategorisasi melalui pengenalan pola yang efektif [17].

Setelah model DenseNet-121 dan ResNet-101 dimuat, selanjutnya yaitu dibuatkannya model tambahan yang berisi lima lapisan atau *layer*, lapisan pertama yaitu lapisan untuk *base model* yang berguna untuk memuat model awal yang sudah dimuat yaitu model DenseNet-121 dan model ResNet-101. Lapisan kedua yaitu *GlobalAveragePooling2D* yang berguna untuk mengekstraksi fitur global dari setiap lapisan atau modul [18]. Lapisan ketiga yaitu lapisan *Dense* yang berisi 64 unit dan menggunakan aktivasi '*relu*'. Lapisan keempat yaitu *Dropout* dengan *dropout rate* sebesar 0.3. Dan pada lapisan kelima atau terakhir yaitu lapisan *Dense* dengan *output* bernilai 4 dengan aktivasi '*softmax*' untuk menghasilkan keluaran dengan 4 pilihan sesuai kelas pada dataset yaitu *brown spot*, *healthy*, *hispa*, dan *leaf blast*.


Lalu kedua model DenseNet-121 dan ResNet-101 dilakukan *compiling* dengan *optimizer* SGD dengan *learning rate* sebesar 0.001, menggunakan *loss* berjenis *categorical entropy* dan menggunakan *accuracy* sebagai *metrics*-nya.

Evaluasi Model

Pada tahap terakhir atau pada tahap evaluasi model yang dimana merupakan sebuah tahap yang krusial untuk mengumpulkan data secara sistematis sehingga dapat menilai dan meningkatkan kualitas dari pembelajaran model [19]. Pada penelitian ini yaitu dilakukannya pengukuran tingkat akurasi atau performa dari model yang telah dilatih dengan melakukan perbandingan antara prediksi dan label sesungguhnya, seperti dibuatnya *confusion matrix* yang dapat dilihat pada bagian hasil dan pembahasan..

III. HASIL DAN PEMBAHASAN


Setelah dilakukan proses pengumpulan data, pemrosesan awal data, klasifikasi data, dan evaluasi data yang telah dilakukan maka telah didapatkannya sebuah kesimpulan yaitu bahwa hasil akurasi dari model yang dibuat menggunakan *premodel DenseNet-121* mendapatkan akurasi pelatihan sebesar 79.86% dengan akurasi validasi sebesar 47.31% yang dapat dilihat pada gambar 3.



Gambar 3. Akurasi dari pelatihan dan validasi model DenseNet-121

Dapat diketahui bahwa hasil yang didapatkan oleh model *DenseNet-121* memiliki akurasi yang kecil bahkan memiliki kemungkinan untuk mengalami *overfitting* yang dimana model hanya dapat memprediksi data pada pelatihan saja.

Adapun hasil dari model deteksi penyakit pada daun padi yang menggunakan *ResNet-101* mendapatkan hasil akurasi pelatihan sebesar 80.02% dan akurasi validasi sebesar 45.51% yang dapat dilihat pada gambar 4.



Gambar 4. Akurasi dari pelatihan dan validasi model ResNet-101

Hasil yang didapatkan pada model dengan *premodel ResNet-101* juga mendapatkan akurasi validasi yang rendah sehingga memungkinkan mengalami masalah *overfitting* yang dimana model hanya bisa memprediksi data pada pelatihan saja sehingga tidak cocok untuk melakukan deteksi penyakit pada daun padi.

Didapatkannya juga sebuah *weighted F1 score* yaitu sebuah metrik yang menggabungkan *precision* dan *recall* untuk memberikan satu nilai tunggal yang dapat dilihat pada tabel 2 dan tabel 3.

TABEL 2
WEIGHTED F1 SCORE MODEL DENGAN DENSENET

	Precision	Recall	F1-Score	Support
Brownspot	0.28	0.46	0.35	26
Gealthy	0.66	0.59	0.62	74
Hispa	0.38	0.36	0.37	38
Leafblast	0.42	0.33	0.37	39
Accuracy			0.47	167
Macro AVG	0.43	0.44	0.43	167
Weighted AVG	0.50	0.47	0.48	167
Weighted F1 Score			0.4795446711381723	


Seperti yang dapat dilihat pada tabel 2 untuk *weighted f1 score* untuk model dengan DenseNet-121 yaitu mendapatkan nilai *weighted f1 score* sebesar 0.4795446711381723.

TABEL 3
WEIGHTED F1 SCORE MODEL DENGAN RESNET

	Precision	Recall	F1-Score	Support
Brownspot	0.33	0.31	0.32	26
Gealthy	0.48	0.92	0.63	74
Hispa	0.	0	0	28
Leafblast	0	0	0	39
Accuracy			0.46	167
Macro AVG	0.20	0.31	0.24	167
Weighted AVG	0.26	0.46	0.33	167
Weighted F1 Score			0.3275322166726455	

Sedangkan pada *weighted f1 score* model dengan ResNet-101 yang dapat dilihat pada tabel 3 yaitu mendapatkan nilai *weighted f1 score* sebesar 0.3275322166726455.

Adapun bentuk dari *confusion matrix* nya yang dimana *confusion matrix* sendiri digunakan untuk mengevaluasi performa klasifikasi, khususnya pada masalah klasifikasi hierarki. Digunakannya *confusion matrix* memungkinkan untuk melihat keakuratan prediksi model dengan membandingkan label yang diprediksi dengan label yang sebenarnya yang dapat dilihat pada gambar 5 [20].



Gambar 5. Confusion matrix dari ensembled learning

Seperti yang dapat dilihat pada gambar 5 atau *confusion matrix*, didapatkan bahwa model cukup mampu untuk memprediksi jawaban yang benar, walaupun masih banyak jawaban yang tidak sesuai karena pada hasil sebelumnya yaitu kedua model masih mengalami *overfitting* sehingga saat dilakukan pengujian hasilnya tidak akurat.

IV. KESIMPULAN

Setelah dilakukannya penelitian ini maka didapatkannya sebuah kesimpulan bahwa telah dibuatnya sebuah model deteksi penyakit pada daun padi dengan menggunakan gabungan dari model *DenseNet-121* dan *ResNet-101* dengan metode *boosting* sehingga didapatkan akurasi dari *ensembled learning* sebesar 52.69%, untuk akurasi dari model *DenseNet-121* dan *ResNet-101* yaitu mendapatkan akurasi sebesar 79.86% dan 80.02% secara berurutan, walaupun model mendapatkan akurasi sekitar 80% namun model yang dibuat masih mengalami *overfitting* yang dapat dilihat pada akurasi validasinya yang berbeda jauh dari akurasinya sehingga model ini belum bisa mendeteksi penyakit pada daun tanaman padi secara efektif.

Adapun saran untuk pengembangan pada penelitian ini yaitu diharapkan ada perbaikan model sehingga model dapat memiliki akurasi yang tinggi atau tidak mengalami *overfitting* sehingga dapat mengurangnya salah prediksi dari model yang dibuat sehingga dapat memprediksi penyakit pada daun padi secara akurat dan jika model ini sudah sempurna maka model ini dapat diimplementasikan pada *handphone* sehingga memudahkan petani untuk memakainya.

DAFTAR PUSTAKA

- [1] Ari Welianto, "Mengapa Tanaman Padi Penting bagi Masyarakat Indonesia?," https://www.kompas.com/skola/read/2020/09/13/170000869/mengapa-tanaman-padi-penting-bagi-masyarakat-indonesia-#google_vignette.
- [2] "Kenali Hama dan Penyakit Pada Tanaman Padi," <https://upland.psp.pertanian.go.id/artikel/1697273234/kenali-hama-dan-penyakit-pada-tanaman-padi>.
- [3] Mrs. J. S. Bhanu, E. Mayukha, S. Shriya, and K. Vineeth, "Rice Leaf Disease Detection using Deep Learning," *Int J Res Appl Sci Eng Technol*, vol. 12, no. 4, pp. 1191–1193, Apr. 2024, doi: 10.22214/ijraset.2024.59979.
- [4] S. Chakraborty, A. Roy, P. Pramanik, D. Valenkova, and R. Sarkar, "A Dual Attention-aided DenseNet-121 for Classification of Glaucoma from Fundus Images," Jun. 2024, [Online]. Available: <http://arxiv.org/abs/2406.15113>
- [5] P. K. Sharma, C. Bhardwaj, R. Mishra, and D. Sharma, "A ResNet-101 Based Recommendation System for E-Commerce," in *2024 11th International Conference on Reliability, Infocom Technologies and Optimization (Trends and Future Directions) (ICRITO)*, IEEE, Mar. 2024, pp. 1–7. doi: 10.1109/ICRITO61523.2024.10522251.

- [6] S. Sheila, M. Kharil Anwar, A. B. Saputra, R. Pujianto, and I. P. Sari, "Deteksi Penyakit pada Daun Padi Berbasis Pengolahan Citra Menggunakan Metode Convolutional Neural Network (CNN)." [Online]. Available: <https://www.kaggle.com/datasets/tedisetiady/leaf->
- [7] A. Stephen, A. Punitha, and A. Chandrasekar, "Designing self attention-based ResNet architecture for rice leaf disease classification," *Neural Comput Appl*, vol. 35, no. 9, pp. 6737–6751, Mar. 2023, doi: 10.1007/s00521-022-07793-2.
- [8] Md. S. Islam Sobuj, Md. I. Hossen, Md. F. Mahmud, and M. U. Islam Khan, "Leveraging Pre-trained CNNs for Efficient Feature Extraction in Rice Leaf Disease Classification," in *2024 International Conference on Advances in Computing, Communication, Electrical, and Smart Systems (iCACCESS)*, IEEE, Mar. 2024, pp. 01–06. doi: 10.1109/iCACCESS61735.2024.10499603.
- [9] R. Thilagavathy, S. S. Kumar, R. Deebalakshmi, D. Deepa, R. Kavitha, and L. S. Kumar, "Advancements in Crown Sheath Rot Detection using DenseNet121 and UNet in Rice Plant Leaf Analysis," in *2023 International Conference on Data Science, Agents & Artificial Intelligence (ICDSAAI)*, IEEE, Dec. 2023, pp. 1–5. doi: 10.1109/ICDSAAI59313.2023.10452450.
- [10] B. Srinivasa Rao, R. Vijaya Kumar Reddy, D. Manogna, K. Akhil, and D. D. Sree, "Identification of Nutrient Deficiency in Rice Leaves using DenseNet-121," in *2022 International Conference on Edge Computing and Applications (ICECAA)*, IEEE, Oct. 2022, pp. 1573–1578. doi: 10.1109/ICECAA55415.2022.9936191.
- [11] A. Agustina, F. Yanto, E. Budianita, I. Iskandar, and F. Syafria, "Klasifikasi Penyakit Tanaman Padi Menggunakan Metode CNN Arsitektur DenseNet-121 dan Augmentasi Data," *Journal Of Information Systems And Informatics Engineering*, vol. 8, no. 1, 2024, doi: 10.35145/joisie.v8i1.4256.
- [12] Q.-H. Trinh and M.-V. Nguyen, "Dense-Res Net for Endoscopic Image Classification," *Academy and Industry Research Collaboration Center (AIRCC)*, Jul. 2021, pp. 101–108. doi: 10.5121/csit.2021.111108.
- [13] "Pengertian Data, Fungsi, Jenis-jenis, Manfaat dan Contohnya," <https://telkomuniversity.ac.id/pengertian-data-fungsi-jenis-jenis-manfaat-dan-contohnya/>.
- [14] K. Riehl, M. Neunteufel, and M. Hemberg, "Hierarchical confusion matrix for classification performance evaluation," *J R Stat Soc Ser C Appl Stat*, vol. 72, no. 5, pp. 1394–1412, Dec. 2023, doi: 10.1093/jrsssc/qlad057.
- [15] "Praproses Data dalam Penambangan Data," <https://www.geeksforgeeks.org/data-preprocessing-in-data-mining/>.
- [16] k Ramesh Babu, S. Salma Sultana, R. Navya Sri, R. S. K, and U. Angel Minerva, "Cardiovascular Risk Assessment with Retinal Images using Densenet-121," *International Research Journal of Modernization in Engineering Technology and Science*, Mar. 2024, doi: 10.56726/irjmets50380.
- [17] K. K. K *et al.*, "Resnet -101 and Faster R-CNN Fusion Accurate Brain Tumor Detection and Categorization," in *2024 2nd International Conference on Artificial Intelligence and Machine Learning Applications Theme: Healthcare and Internet of Things (AIMLA)*, IEEE, Mar. 2024, pp. 1–6. doi: 10.1109/AIMLA59606.2024.10531315.
- [18] S. Cao, S. Long, W. Zhu, F. Liao, Z. Yuan, and X. Guan, "Multiple Layers Global Average Pooling Fusion," 2023, pp. 3–10. doi: 10.1007/978-3-031-20738-9_1.
- [19] M. Iqbal, I. Savitri, F. Hanifah, N. Alfiana Kholizah, D. A. Sari, and T. Munawwarah, "Model Evaluasi Program Pendidikan Terhadap Peningkatan Kualitas Pembelajaran," *Indo-MathEdu Intellectuals Journal*, vol. 5, no. 3, pp. 3535–3540, Jul. 2024, doi: 10.54373/imeij.v5i3.1472.
- [20] C. D. Mellinger and T. A. Hanson, "Research data," in *The Routledge Handbook of Translation and Methodology*, London: Routledge, 2022, pp. 307–323. doi: 10.4324/9781315158945-23.